

Documentación Técnica: Proceso de Etiquetado de Accidentes en Modelos GNN

Equipo de Ingeniería de Datos (SUMO)

2 de febrero de 2026

Resumen

Este documento detalla el procedimiento algorítmico y matemático utilizado para la asignación de etiquetas (labels) de accidentes en la generación de grafos para redes neuronales (GNN). Se describen las dos metodologías implementadas: *Snapshot Features* (secuencias temporales con horizonte de predicción) y *Flow Features* (predicción inmediata a 5 minutos), con énfasis en la normalización temporal, ventanas de búsqueda y propagación espacial de etiquetas.

Índice

1. Introducción	1
2. Definiciones y Normalización	2
2.1. Dominio Temporal Discretizado	2
3. Metodología 1: Snapshot Features (Secuencias Temporales)	2
3.1. Parámetros de Configuración	2
3.2. Definición de Ventana de Etiquetado	2
3.3. Propagación Espacial (Lógica Downstream)	2
3.4. Función de Etiquetado	3
3.5. Ejemplo Numérico	3
4. Metodología 2: Flow Features (5 min / Next-Step)	3
4.1. Alineación por Desplazamiento (Shift)	3
4.2. Criterio Espacial	4
4.3. Función de Etiquetado	4
5. Consideraciones de Auditoría	4
5.1. Consistencia Topológica	4
5.2. Multiplicidad de Etiquetas	4

1. Introducción

El objetivo del módulo de etiquetado es transformar un registro discreto de eventos (accidentes) en una señal supervisada $y \in \{0, 1\}$ alineada con las características de tráfico (features) de la red vial. Dado que los accidentes son eventos puntuales en el espacio-tiempo (p_a, t_a) , y el tráfico se mide en intervalos discretos y ubicaciones fijas, es necesario un proceso de mapeo riguroso.

2. Definiciones y Normalización

2.1. Dominio Temporal Discretizado

El tiempo se modela como una secuencia discreta de intervalos de longitud Δt (típicamente $\Delta t = 5$ minutos).

Sea T_{raw} una marca de tiempo continua (timestamp). Definimos el tiempo normalizado ts_{min} como el número entero de minutos desde una época de referencia (Unix Epoch).

$$ts_{min}(T) = \lfloor \frac{T_{epoch}}{60} \rfloor \quad (1)$$

Para alinear los eventos a la rejilla de los features, definimos una función de discretización $Disc(T, \Delta t)$:

$$Disc(T, \Delta t) = \lfloor \frac{ts_{min}(T)}{\Delta t} \rfloor \times \Delta t \quad (2)$$

Esta transformación asegura que tanto los features de flujo como los accidentes se encuentren en el mismo dominio de tiempo entero.

3. Metodología 1: Snapshot Features (Secuencias Temporales)

Esta metodología busca predecir la ocurrencia de un accidente en un horizonte futuro $[t_{start}, t_{end}]$, basándose en una secuencia de estados pasados del tráfico.

3.1. Parámetros de Configuración

- L : Longitud de la secuencia de entrada (Sequence Length).
- GB : Banda de guarda (Guard Band) en minutos. Tiempo muerto entre la última observación y el inicio de la predicción.
- H : Horizonte de predicción (Horizon) en minutos. Duración de la ventana de riesgo.

3.2. Definición de Ventana de Etiquetado

Sea $x_i(t)$ el vector de características del nodo (pórtico) i en el tiempo t . Queremos asignar una etiqueta $y_i(t)$.

El intervalo de tiempo efectivo para la búsqueda de accidentes, denominado *Ventana Objetivo* $W(t)$, se define como:

$$W(t) = [t + GB, \quad t + GB + H] \quad (3)$$

Donde t representa el tiempo final de la secuencia de entrada (último feature observado).

3.3. Propagación Espacial (Lógica Downstream)

Para capturar la congestión que se propaga hacia atrás, la etiqueta del nodo i depende no solo de los accidentes en i , sino también de los accidentes en su nodo vecino inmediato aguas abajo, denotado como $ds(i)$.

Sea A el conjunto de todos los accidentes, donde cada accidente $a \in A$ es un par (p_a, t_a) de ubicación y tiempo.

El conjunto de accidentes relevantes para el nodo i , denotado como A_i , es:

$$A_i = \{(p, t) \in A \mid p = i \vee p = ds(i)\} \quad (4)$$

Es decir, consideramos accidentes en el propio nodo o en el siguiente tramo.

3.4. Función de Etiquetado

La etiqueta binaria $y_i(t)$ se define formalmente como:

$$y_i(t) = \begin{cases} 1 & \text{si } \exists(p, \tau) \in A_i \text{ tal que } \tau \in W(t) \\ 0 & \text{en otro caso} \end{cases} \quad (5)$$

En términos algorítmicos, esto se implementa mediante búsqueda binaria ('searchsorted') sobre los tiempos de accidentes ordenados para verificar la intersección con el intervalo $[t+GB, t+GB+H]$.

3.5. Ejemplo Numérico

Configuración: $t = 10 : 00$, $\Delta t = 5$, $GB = 10$, $H = 20$. (Suponiendo GB incluye el propio dt de predicción si se requiere).

- Último feature observado: 10:00.
- Inicio ventana: $10 : 00 + 10 = 10 : 10$.
- Fin ventana: $10 : 10 + 20 = 10 : 30$.
- Si ocurre un accidente en i o $ds(i)$ a las 10:15, entonces $y_i(10 : 00) = 1$.

4. Metodología 2: Flow Features (5 min / Next-Step)

Esta metodología es una simplificación diseñada para modelos tabulares o GNNs que predicen estrictamente el siguiente paso temporal (Δt).

4.1. Alineación por Desplazamiento (Shift)

En lugar de definir ventanas flexibles, se asume que los features en el tiempo t deben predecir el accidente que ocurrirá en $t + \Delta t$.

Para lograr esto mediante un *Join* (cruce) exacto de bases de datos, se transforman los tiempos de los accidentes.

Sea t_a el tiempo real de un accidente.

1. **Discretización (Floor):** $t'_a = \lfloor t_a / \Delta t \rfloor \times \Delta t$.

2. **Desplazamiento (Shift):** $t''_a = t'_a - \Delta t$.

El tiempo t''_a representa el "tiempo de los features previos" que deberían haber alertado sobre el accidente.

4.2. Criterio Espacial

En la metodología Flow, la asignación es estrictamente local por defecto (salvo que se pre-procesen features de vecindario).

$$A_i^{Flow} = \{(p, t) \in A \mid p = i\} \quad (6)$$

4.3. Función de Etiquetado

La etiqueta $y_i(t)$ se obtiene mediante la función indicadora:

$$y_i(t) = \mathbb{I} \left(\exists (p, \tau) \in A_i^{Flow} \text{ tal que } \tau_{shifted} = t \right) \quad (7)$$

Donde $\tau_{shifted}$ es el resultado de aplicar el paso 1 y 2 al tiempo del accidente.

5. Consideraciones de Auditoría

5.1. Consistencia Topológica

Es crítico notar que la lógica *downstream* de la metodología Snapshot depende de la integridad del grafo de pórticos cargado.

- Si se selecciona un sub-grafo (ej. nodos 2, 3, 5, 7), el cálculo de etiquetas para el nodo borde (7) **consulta la topología global**.
- Si existe un nodo 8 en la base de datos maestra de pórticos y ocurren accidentes en él, el nodo 7 será etiquetado positivamente, aunque el nodo 8 no tenga features cargados en el modelo.

5.2. Multiplicidad de Etiquetas

Un único accidente real genera múltiples etiquetas positivas en el dataset de entrenamiento:

1. **Multiplicidad Espacial:** Afecta al nodo del accidente y al nodo upstream (2 nodos afectados).
2. **Multiplicidad Temporal:** Afecta a todos los snapshots cuya ventana futura cubra el instante del accidente ($\approx H/\Delta t$ snapshots).

Esta multiplicación es intencional y necesaria para balancear las clases y enseñar al modelo la evolución temporal del riesgo.