

Análisis de Resultados: Experimentos de Recalibración para Predicción de Crashes

Generado automáticamente

23 de marzo de 2026

Índice

1. Diseño Experimental	2
2. Ranking de Estrategias	2
3. Degradación Temporal del Modelo Estático	2
4. Ventaja de Cumulative vs. Static	3
5. Diagnóstico del Adaptive ADWIN	3
6. Efecto de SMOTE	4
7. Ranking de Modelos	4
8. Conclusiones y Recomendaciones	4

1. Diseño Experimental

Se comparan cuatro estrategias de recalibración para modelos de predicción de crashes, evaluadas sobre el período 2019–2024.

Cuadro 1: Estrategias de recalibración evaluadas.

Estrategia	Datos de entrenamiento	Tamaño
Static	Fijo: año 2018	~94 679 obs
Period-aligned	Año inmediatamente anterior ($N-1$)	50 238–94 099 obs
Cumulative	Todo el histórico ($\leq N-1$)	94 679–471 050 obs
Adaptive ADWIN	Ventana deslizando post-drift	45 000 obs (fija)

Cada estrategia se ejecuta con cuatro modelos base (XGBoost, AdaBoost, Random Forest, NNet) y dos modos de balance de clases (sin balanceo y SMOTE). Adicionalmente, se evaluó Adaptive Random Forest (ARF) como estrategia de streaming puro.

2. Ranking de Estrategias

La Tabla 2 presenta las mejores configuraciones por estrategia, ordenadas por AUC promedio (sin SMOTE).

Cuadro 2: Ranking de estrategias por AUC promedio (balance = none).

#	Estrategia	Modelo	AUC	Sensitivity	Specificity
1	Cumulative	Random Forest	0,796	0,678	0,779
2	Cumulative	XGBoost	0,790	0,718	0,739
3	Static	Random Forest	0,787	0,703	0,750
4	Static	XGBoost	0,778	0,706	0,729
5	Period-aligned	Random Forest	0,776	0,664	0,766
6	Period-aligned	XGBoost	0,771	0,716	0,706
7	ADWIN	Random Forest	0,759	0,612	0,748
8	ADWIN	AdaBoost	0,736	0,713	0,677

Hallazgo principal:

Cumulative > Static > Period-aligned $\gg$ Adaptive ADWIN

3. Degradación Temporal del Modelo Estático

La Tabla 3 muestra cómo evoluciona el AUC del modelo estático (entrenado en 2018) al predecir años sucesivos.

Cuadro 3: AUC por año de predicción — estrategia static, balance = none.

Año Pred.	RF (AUC)	XGBoost (AUC)	Tendencia
2019	0,772	0,769	Baseline
2020	0,761	0,741	Leve caída
2021	0,791	0,781	Recuperación
2022	0,772	0,772	Estable
2023	0,845	0,847	Pico
2024	0,779	0,757	Vuelta a normal

Dos observaciones relevantes:

- 2023 es consistentemente el año más fácil de predecir en **todas** las estrategias.
- El modelo estático **no muestra degradación monotónica**, lo que sugiere que el concept drift en los patrones de crashes no es severo.

4. Ventaja de Cumulative vs. Static

Cuadro 4: Comparación de AUC entre estrategias static y cumulative (balance = none).

Modelo	AUC Static	AUC Cumulative	Δ
Random Forest	0,787	0,796	0,009
*XGBoost	0,778	0,790	0,012
AdaBoost	0,763	0,774	0,011
NNet	0,748	0,747	-0,001

La ganancia del reentrenamiento acumulativo es modesta pero consistente (~ 1 punto de AUC). NNet es el único modelo que no se beneficia de esta estrategia.

5. Diagnóstico del Adaptive ADWIN

ADWIN presenta el peor desempeño entre todas las estrategias. El análisis detallado de los logs de drift revela las siguientes causas:

1. **Exceso de drifts detectados:** entre 18 y 27 reentrenamientos por modelo en 5 años, versus 6 reentrenamientos en las estrategias yearly.
2. **Ventanas de evaluación muy pequeñas:** muchos segmentos post-drift contienen < 100 observaciones, produciendo métricas altamente ruidosas (AUC individual oscila entre 0.17 y 0.97).
3. **Inestabilidad de thresholds:** el umbral de clasificación cambia drásticamente entre reentrenamientos (e.g., NNet oscila entre 0.0004 y 0.41).
4. **NNet es especialmente inestable con ADWIN:** AUC promedio de 0.734 (none) y 0.648 (smote).
5. **ARF es inutilizable:** AUC = 0,471, peor que clasificación aleatoria.

Cuadro 5: Número de reentrenamientos (drifts detectados) por modelo en ADWIN.

Modelo	Drifts (none)	Drifts (smote)
AdaBoost	24	27
Random Forest	26	26
XGBoost	20	23
NNet	18	21

6. Efecto de SMOTE

Cuadro 6: Impacto de SMOTE en el AUC promedio por estrategia (todos los modelos).

Estrategia	AUC sin SMOTE	AUC con SMOTE	Δ
Cumulative	0,787	0,770	-0,017
Static	0,769	0,746	-0,023
Period-aligned	0,761	0,738	-0,023
ADWIN	0,737	0,695	-0,042

SMOTE **perjudica consistentemente** el AUC en todas las estrategias. La caída es más pronunciada en ADWIN, donde las ventanas de entrenamiento pequeñas amplifican el ruido introducido por el oversampling sintético.

7. Ranking de Modelos

Cuadro 7: Rendimiento promedio por modelo (across strategies, balance = none).

Modelo	AUC	Sensitivity	Specificity	Tiempo (s)
Random Forest	0,779	0,664	0,761	67,0
XGBoost	0,770	0,673	0,733	0,7
AdaBoost	0,757	0,696	0,720	28,0
NNet	0,741	0,658	0,687	8,8

XGBoost ofrece el mejor trade-off rendimiento/costo computacional: es $\sim 100\times$ más rápido que Random Forest con solo 0.009 menos de AUC.

8. Conclusiones y Recomendaciones

1. **Mejor configuración absoluta:** Cumulative + Random Forest (sin SMOTE), AUC = 0,796.
2. **Mejor trade-off práctico:** Cumulative + XGBoost (sin SMOTE), AUC = 0,790, con un tiempo de entrenamiento $\sim 70\times$ menor.
3. **Static es competitivo:** Solo ~ 1 punto de AUC por debajo de cumulative. Si el costo operacional de reentrenamiento es alto, el modelo estático es una alternativa viable.
4. **ADWIN no funciona bien en este contexto:** El exceso de falsos drifts, las ventanas pequeñas y las métricas ruidosas degradan significativamente el rendimiento. Posibles mejoras incluyen:

- Aumentar el parámetro δ para reducir sensibilidad.
 - Imponer ventanas mínimas de evaluación más grandes.
 - Implementar un mecanismo de “cooling period” entre reentrenamientos.
5. **SMOTE no ayuda:** El desbalance de clases no parece ser el bottleneck del rendimiento en este problema.
 6. **El drift temporal no es severo:** El modelo entrenado en 2018 mantiene buen rendimiento hasta 2024, sugiriendo que los patrones espaciotemporales de crashes son relativamente estables en el horizonte evaluado.